



# Reinforcement learning

## Введение в DeepRL

• REC

Проверить, идет ли запись

Меня хорошо видно  
&& слышно?



Ставим "+", если все хорошо  
"-", если есть проблемы

# Правила вебинара



Активно  
участвуем



Off-topic обсуждаем  
в учебной группе



Задаем вопрос  
в чат



Вопросы вижу в чате,  
могу ответить не сразу

## Условные обозначения



Индивидуально



Время, необходимое  
на активность



Пишем в чат



Говорим голосом



Документ



Ответьте себе или  
задайте вопрос

Тема вебинара

# Reinforcement learning. Введение в DeepRL

Игорь Стурейко



Руководитель курсов: Reinforcement Learning, ML Professional, ML Basic, MLOps, FinML

Teamlead, главный инженер проекта,  
Физический факультет МГУ, PhD теоретическая физика

Опыт:


Более 15 лет занимался прикладной математикой и мат моделированием  
(Data Scientist) (Python, C++) в НИИ ПАО Газпром

@stureiko (TG)

LinkedIn: [igor-stureiko](#)

@rl\_fintech (Мой канал о моделях в бизнесе)

# Карта курса




# Программа курса



## Deep Reinforcement Learning

- Введение в Deep Reinforcement Learning
- Deep Q-Network (DQN) алгоритм
- Policy Gradient (PG) алгоритм
- Actor-Critic алгоритм
- TRPO -> PPO
- DDPG -> TD3 -> LSTM-TD3

# Маршрут вебинара



# Цели вебинара

К концу занятия вы сможете

1. Понять сложности применения классических алгоритмов к непрерывным средам
2. Понять подход к применению нейросети для предсказания политики
3. Понять применение нейросети в алгоритме кросс-энтропии

# Смысл

## Зачем вам это уметь

1. Понимать границы применимости классических алгоритмов
2. Понимать переход к Deep Reinforcement Learning

# Постановка задачи

# Markov Property

$$\mathbb{P}[S_{t+1}|S_t A_t] = \mathbb{P}[S_{t+1}|S_1 A_1, S_2 A_2, \dots, S_t A_t]$$

$$\mathbb{P}[R_t|S_t A_t] = \mathbb{P}[R_t|S_1 A_1, S_2 A_2, \dots, S_t A_t] = 1$$

# Markov Decision Process $\langle \mathcal{S}, \mathcal{S}_F, \mathcal{A}, \mathcal{P}, \mathcal{P}_0, \mathcal{R}, \gamma \rangle$

- $\mathcal{S}$  – is **an infinite** ( $|\mathcal{S}|= n$ ) state space
- $\mathcal{A}$  – is a **finite/infinite** ( $|\mathcal{A}|=m$ ) action space
- $\mathcal{P}$  – is **a known** deterministic transition probability function


$$\mathcal{P}(s'|s, a) = \mathbb{P}[S_{t+1} = s' | S_t = s, A_t = a]$$

- $\mathcal{P}_0$  – is a deterministic initial state probability function
  - $\mathcal{R}$  – is **a known** reward function
- $$\mathcal{R}(s, a) = R_t, \Leftrightarrow \mathbb{P}[R_t | S_t = s, A_t = a] = 1$$
- $\gamma \in [0, 1]$  – is a discount coefficient



# Применение классического RL в непрерывной среде

# CartPole



Action Space	Discrete(2)
Observation Space	Box( [-4.8000002e+00 -3.4028235e+38 -4.1887903e-01 -3.4028235e+38], [4.8000002e+00 3.4028235e+38 4.1887903e-01 3.4028235e+38], (4,), float32)



# SARSA and Q-learning

- Устанавливаем  $Q(s,a)=0, K>0, \varepsilon=1$ .
- Для каждого  $k \in 1, K$ :  
двигаясь по текущей траектории из состояния  $S_t$  действуя  $A_t$  в силу политики  $\pi(\cdot | S_t)$ , и обновляя политику  $\pi = \varepsilon$ -greedy( $Q$ ) получаем  $R_t$  и переходим в состояние  $S_{t+1}$  с действием  $A_{t+1} \sim \pi(\cdot | S_{t+1})$
- Обновляем  $Q$ :

Q-learning	SARSA
$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left( R_t + \gamma \max_{a'} Q(S_{t+1}, a') - Q(S_t, A_t) \right)$	$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left( R_t + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t) \right)$

- Обновляем  $\varepsilon = 1/k$




# CartPole дискретизация среды

- Разделим пространство состояний на дискретные интервалы. Тогда размер q-таблицы в памяти будет следующий:
- 10 интервалов =  $\frac{10^4 \cdot 2 \cdot 32\text{bit}}{1024^2} = 0.6 \text{ Mb}$ , 20.000 состояний q-table
- 20 интервалов =  $\frac{20^4 \cdot 2 \cdot 32\text{bit}}{1024^2} = 9.77 \text{ Mb}$ , 320.000 состояний q-table
- 50 интервалов =  $\frac{50^4 \cdot 2 \cdot 32\text{bit}}{1024^2} = 381,74 \text{ Mb}$ , 12.500.000 состояний q-table
- 100 интервалов =  $\frac{100^4 \cdot 2 \cdot 32\text{bit}}{1024^2} = 6.1 \text{ Gb}$ , 200.000.000 состояний q-table

Когда мы рассматривали Taxi там было 500 состояний.

# CartPole дискретизация среды



$n = 20$

$\text{discrete\_state\_n} = 320.000$

$\text{episode\_n} = 100.000 \times 10$



# Deep cross-entropy

# Метод кросс-энтропии

## 1. Оценка политики $\mathbb{E}_\pi[G]$

- Устанавливаем начальное состояние  $S_0$  и политику  $\pi_0$
- Действуем  $A_0=\pi(S_0)$ , получаем награду  $R_0=(S_0, A_0)$  и переходим в состояние  $S_1$
- ...
- Получили траекторию  $\tau=\{S_0, A_0, S_1, A_1, \dots, S_F\}$ , и награду по траектории  $G(\tau) = \sum_{t=0}^{T-1} \gamma R_t$

## 2. Улучшение политики $\pi \rightarrow \pi'$ ( $\mathbb{E}_{\pi'}[G] \geq \mathbb{E}_\pi[G]$ )

- Выбираем  $k\%$  лучших траекторий
- "Улучшаем" политику ← собираем средние действия по каждому состоянию
- Назначаем новой политикой среднее действие по лучшим траекториям в каждом состоянии



# Deep Cross-entropy

Пусть у нас  $S \in \mathbb{R}^n$  и  $\mathcal{A} \in \mathbb{R}^m$ , т.е. пространство действий и пространство состояний конечномерно и непрерывно.

Будем использовать нейросеть  $F^\theta$  для аппроксимации политики, т.е  $F^\theta: \mathbb{R}^n \mapsto \mathbb{R}^m$ ,  $\theta$  – веса нейросети.  
Будем действовать в среде  $N$  раз (эпизодов обучения) и соберем  $K$  траекторий для каждого эпизода.  
Тогда на каждом эпизоде обучения  $n \in [1, N]$ :

$$\pi_n(s) = [F^{\theta_n}(s) + noise(\varepsilon)]_{\mathcal{A}}$$

**Оценка политики  $\mathbb{E}_\pi[G]$ :**

Подавая на вход сети состояние  $s$  получаем оценку действия  $a$  и действуя получаем следующее состояние.  
Получаем траекторию в среде.

$$\mathbb{E}_{\pi_n}[G] = \frac{1}{K} \sum_{k=1}^K G(\tau_k)$$

Нам необходимо найти «наилучшие» действия по конечному набору точек – задача регрессии.

# Deep CrossEntropy

**Улучшение политики** для каждого эпизода обучения  $n \in [1, N]$ :

Выбираем «элитные» траектории и усредняем действие на них для каждого состояния.

Затем считаем лосс и обновляем веса модели:

$$Loss(\theta_n) = \frac{1}{|\tau_n|} \sum_{(a|s) \in \tau_n} \|F^{\theta_n}(s) - a\|^2$$

$$\theta_{n+1} = \theta_n - \eta \nabla_{\theta} Loss(\theta_n)$$

# Вопросы?




Ставим “+”,  
если вопросы есть



Ставим “-”,  
если вопросов нет


# Окружения

# CartPole



Action Space	Discrete(2)
Observation Space	Box( [-4.8000002e+00 -3.4028235e+38 -4.1887903e-01 -3.4028235e+38], [ 4.8000002e+00 3.4028235e+38 4.1887903e-01 3.4028235e+38], (4,), float32)


# LunaLander



Action Space	Discrete(4)
Observation Space	Box( [-1.5 -1.5 -5. -5. -3.1415927 -5. -0. 0. ], [ 1.5 1.5 5. 5. 3.1415927 5. 1. 1. ], (8,), float32)



# MountainCar



Action Space	Discrete(3)
Observation Space	Box( [-1.2 -0.07], [0.6 0.07], (2,), float32)



# CarRacing



Action Space	Box([-1. 0. 0.], 1.0, (3,), float32)
Observation Space	Box( 0, 255, (96, 96, 3), uint8)



# Atari battleZone



Action Space	Discrete(18)
Observation Space	Box( 0, 255, (210, 160, 3), uint8)



# Практика

# Практика

1. Дискретизация CartPole

---

2. Deep Cross-Entropy метод

---

# Вопросы?



Ставим “+”,  
если вопросы есть



Ставим “-”,  
если вопросов нет

**Заполните, пожалуйста,  
опрос о занятии  
по ссылке в чате**

Спасибо за внимание!

# Следующие вебинары

Deep q-learning (DQN)

Игорь Стурейко



Руководитель курсов: Reinforcement Learning, ML Professional, ML Basic, MLOps, FinML

Teamlead, главный инженер проекта,  
Физический факультет МГУ, PhD теоретическая физика

**Опыт:**

Более 15 лет занимался прикладной математикой и мат моделированием  
(Data Scientist) (Python, C++) в НИИ ПАО Газпром

@stureiko (TG)

LinkedIn: [igor-stureiko](#)

@rl\_fintech (Мой канал о моделях в бизнесе)