Reinforcement Learning

Обучение с использованием модели среды

otus.ru

REC **Проверить, идет ли запись**

Меня хорошо видно && слышно?

Ставим “+”, если все хорошо
“-”, если есть проблемы

Тема вебинара

Reinforcement Learning

Обучение с использованием модели среды

Андрей Канашов

Team Lead Data Scientist в ПИК

- Ценообразование и тарификация
- Рекомендательные системы
- Прогнозирование ключевых метрик
- Анализ клиентского поведения

Правила вебинара

Активно
участвуем

Off-topic обсуждаем
в учебной группе TG

Задаем вопрос
в чат или голосом

Вопросы вижу в чате,
могу ответить не сразу

Условные обозначения

Индивидуально

Время, необходимое
на активность

Пишем в чат

Говорим голосом

Документ

Ответьте себе или
задайте вопрос

Маршрут вебинара

- Знакомство
- Model-based подход
- Обучение в воображении
- Планирование в воображении
- Практика
- Рефлексия

Цели вебинара

К концу занятия вы узнаете

1. Что такое модель среды и как её обучить
2. Сильные и слабые стороны model-free и model-based подходов
3. Что такое планирование в контексте RL и какие задачи решает
4. Как реализовать простой алгоритм планирования в воображении

Model-based RL

Часть 1

Что понимается под моделью среды в RL?

Интуитивное описание модели

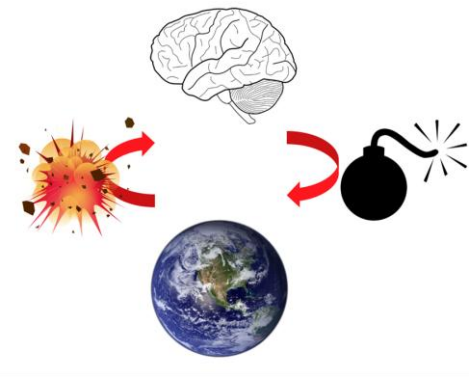

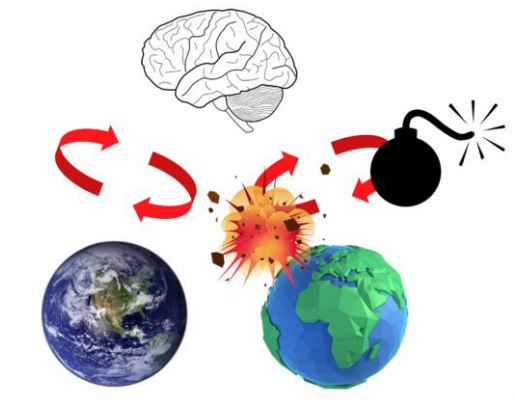

Формальное описание модели

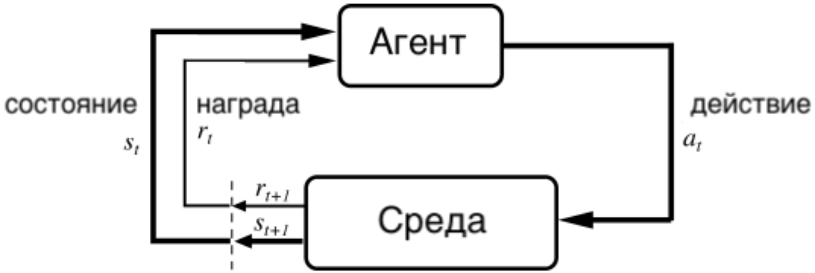

- A *model* $\mathcal{M}$ is a representation of an MDP $\langle \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R} \rangle$, parametrized by η
- We will assume state space $\mathcal{S}$ and action space $\mathcal{A}$ are known
- So a model $\mathcal{M} = \langle \mathcal{P}_\eta, \mathcal{R}_\eta \rangle$ represents state transitions $\mathcal{P}_\eta \approx \mathcal{P}$ and rewards $\mathcal{R}_\eta \approx \mathcal{R}$

$$S_{t+1} \sim \mathcal{P}_\eta(S_{t+1} \mid S_t, A_t)$$
$$R_{t+1} = \mathcal{R}_\eta(R_{t+1} \mid S_t, A_t)$$

- Typically assume conditional independence between state transitions and rewards

$$\mathbb{P}\left[S_{t+1}, R_{t+1} \mid S_t, A_t\right] = \mathbb{P}\left[S_{t+1} \mid S_t, A_t\right] \mathbb{P}\left[R_{t+1} \mid S_t, A_t\right]$$

Преимущества от использования модели

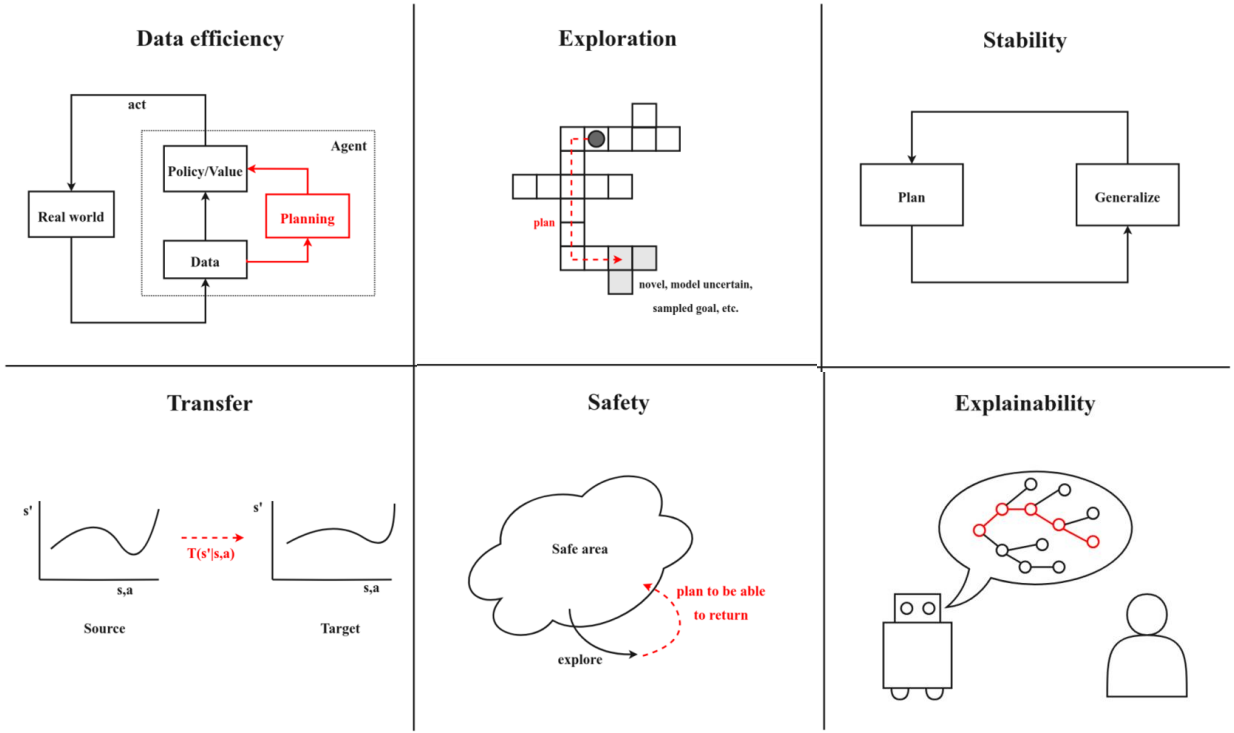

Сравнение с безмодельными подходами

Model-free

- Легче реализовать
- Не нужно выучивать динамику среды

- Требуется гораздо больше взаимодействий со средой
- Агенты совершают много ошибок в реальной среде
- Нет возможность оценивать доступные действия с помощью планирования

Model-based

- Требуется меньше взаимодействий со средой
- Выучив модель среды, можно решать разные задачи
- Быстрее сходятся к оптимальному решению

- Требуется модель среды
- Обучение зависит от качества модели среды
- Более длительное время принятия решений из за планирования

Как получить модель среды?

С помощью описания

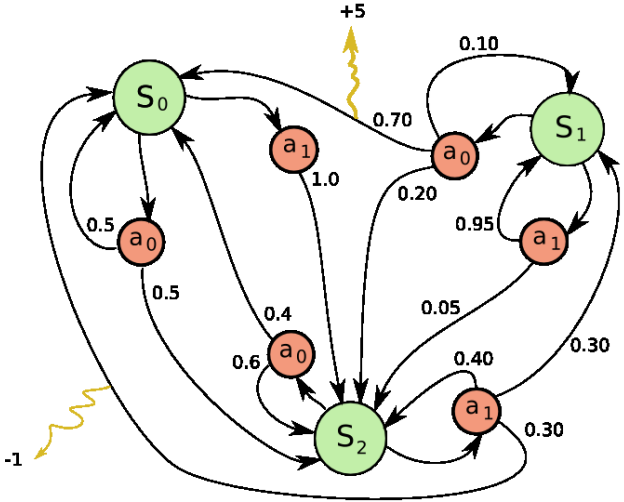

С помощью обучения

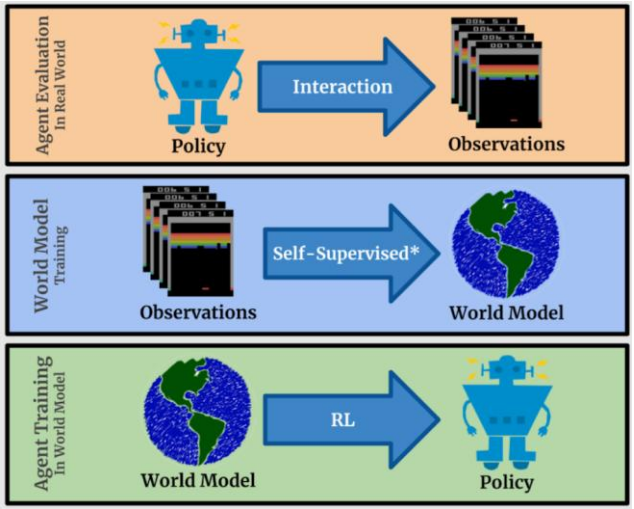

Базовый сценарий применения модели

1. Повзаимодействовать со средой при помощи случайно стратегии и добавить в буфер памяти встреченные переходы {s, a, r, s'}
2. Провести дообучение модели мира на собранных данных
3. Использовать модель среды в качестве симулятора для генерации траекторий из текущего состояния
4. Выбрать первое действие наиболее успешной траектории, сохранить в буфер новый переход
5. Продолжать шаги 3 - 4 до завершения эпизода
6. Продолжать шаги 2 - 5 до достижения желаемого качества модели

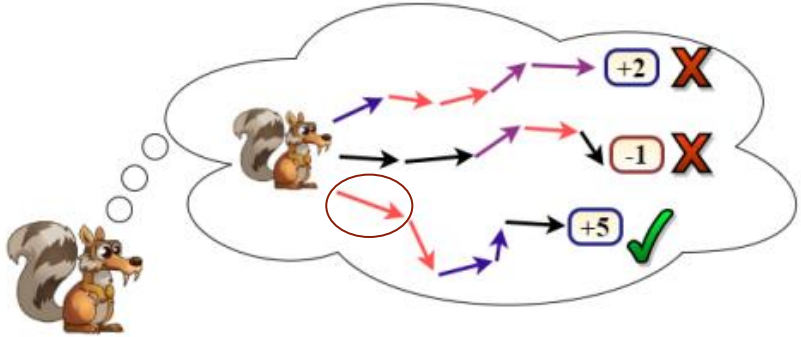

Примеры других сценариев

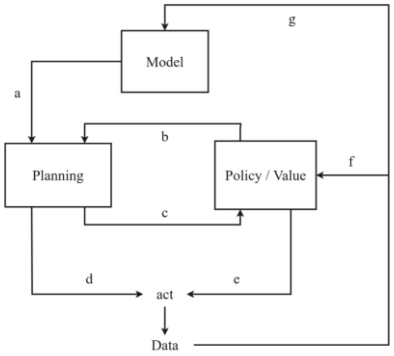

Dyna

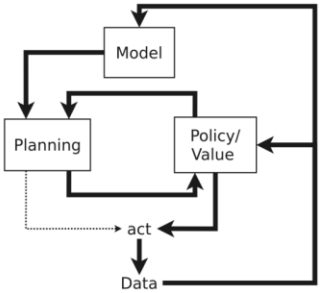

AlphaGoZero

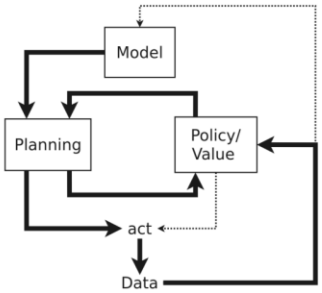

a. Планирование с помощью модели

b. Использование прогнозов ценности / действий во время планирования

c. Использования результатов планирования для дообучения функций стратегии / ценности

d. Выбор действия на основе планирования

e. Выбор действия с помощью функций стратегии / ценности

f. Обучение стратегии / функции ценности на реальных данных

g. Обучение модели на реальных данных

Embed2Control

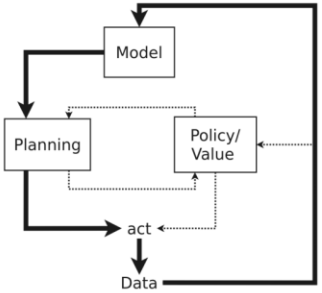

DQN / SARSA

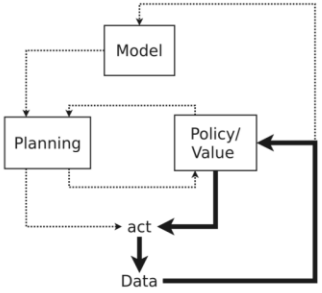

Dyna

Model-Free RL

- Нет модели
- Изучает функцию ценности (и/или политику) из реального опыта

Model-Based RL (using Sample-Based Planning)

- Изучает модель из реального опыта
- Планирует функцию ценности (и/или политику) из смоделированного опыта

Dyna

- Изучает модель из реального опыта
- Изучает и планирует функцию ценности (и/или политику) из реального и смоделированного опыта

Планирование в RL

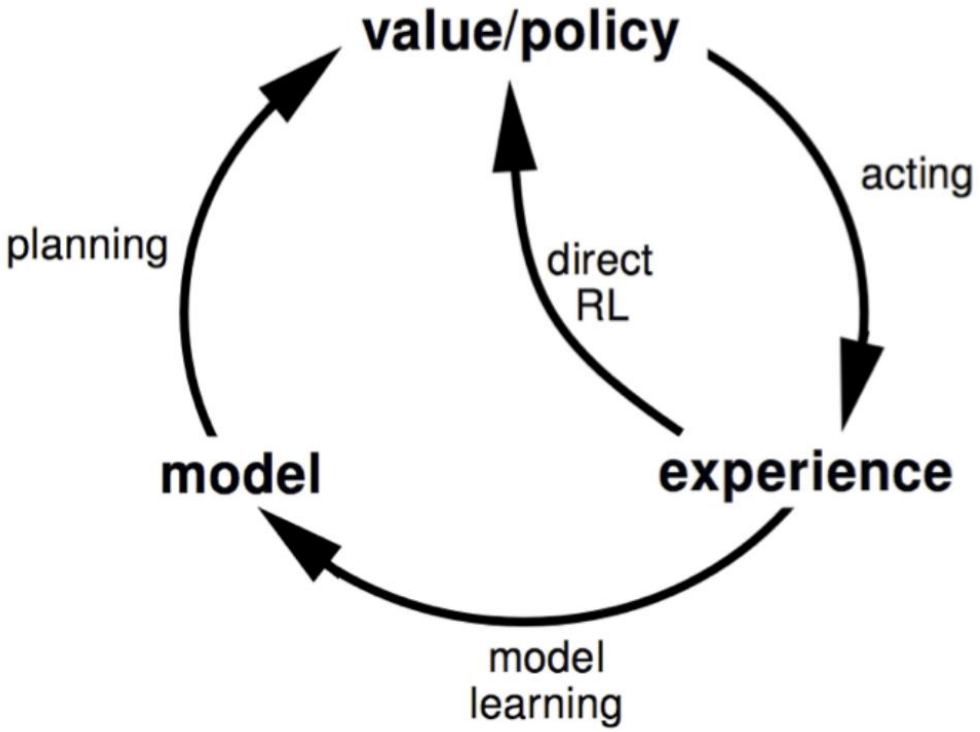

Обучение
в воображении

Семейство Dyna-алгоритмов

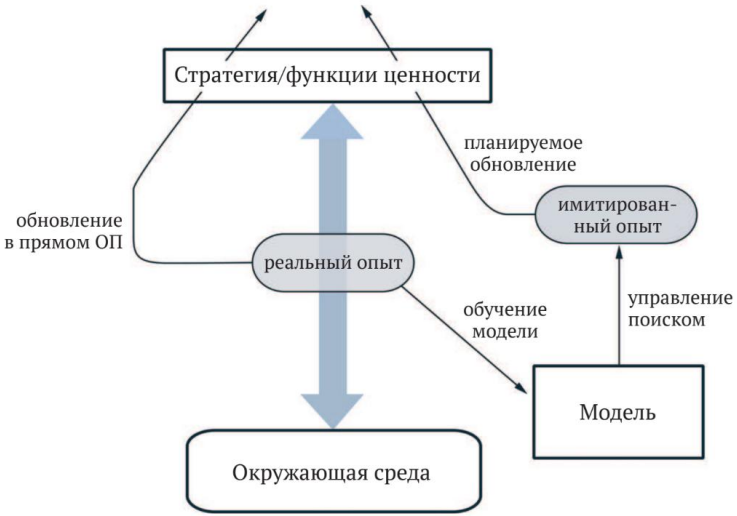

Табличный Dyna-Q

Инициализировать $Q(s, a)$ и $Model(s, a)$ для всех $s \in \mathcal{S}$ и $a \in \mathcal{A}(S)$
Повторять бесконечно:
(a) $S \leftarrow$ текущее (незаключительное) состояние
(b) $A \leftarrow \varepsilon$-жадная(S, Q)
(c) Предпринять действие A; наблюдать результирующее вознаграждение R и состояние S'
(d) $Q(S, A) \leftarrow Q(S, A) + \alpha[R + \gamma \max_a Q(S', a) - Q(S, A)]$
(e) $Model(S, A) \leftarrow R, S'$ (в предположении детерминированной среды)
(f) Повторить n раз:
$S \leftarrow$ случайное ранее наблюдавшееся состояние
$A \leftarrow$ случайное действие, ранее предпринятое в состоянии S
$R, S' \leftarrow Model(S, A)$
$Q(S, A) \leftarrow Q(S, A) + \alpha[R + \gamma \max_a Q(S', a) - Q(S, A)]$

Семейство Dyna-алгоритмов

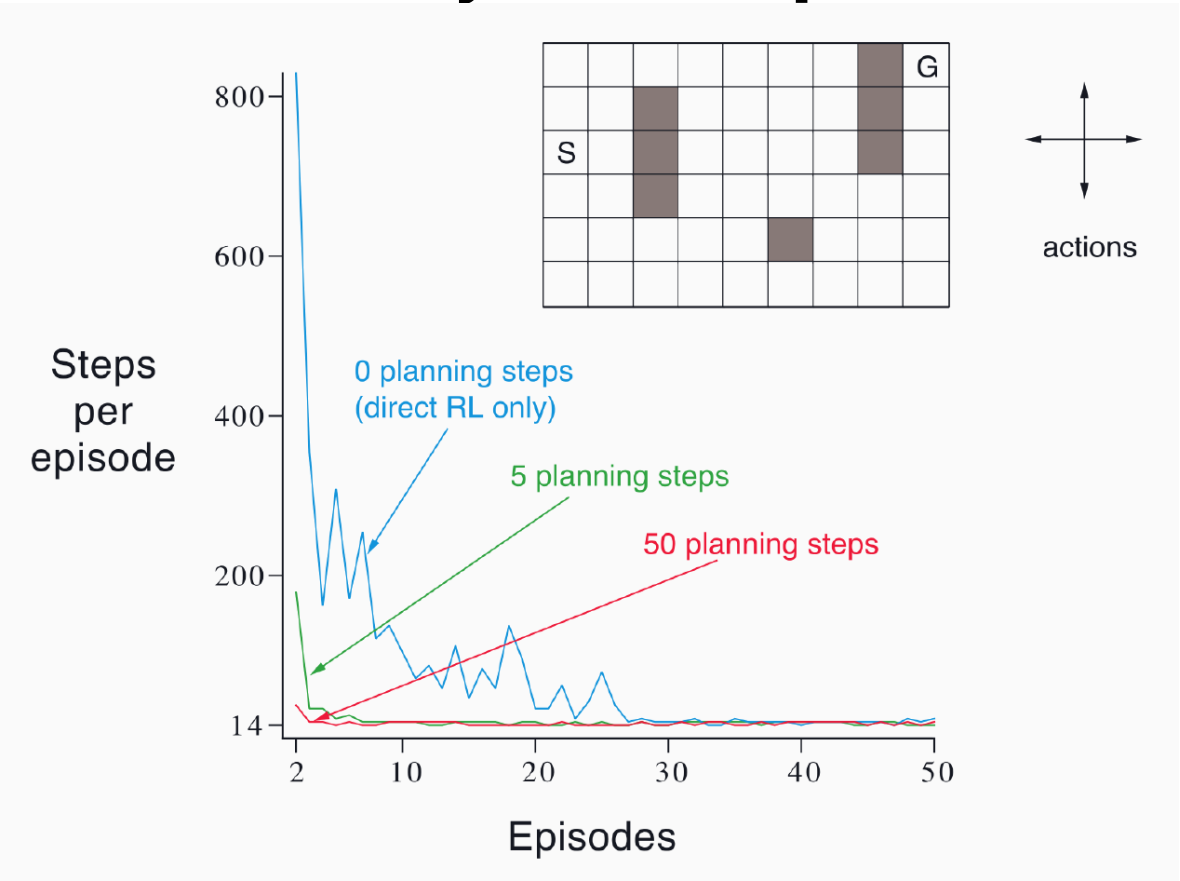

Планирование в воображении

Модель прямой динамики

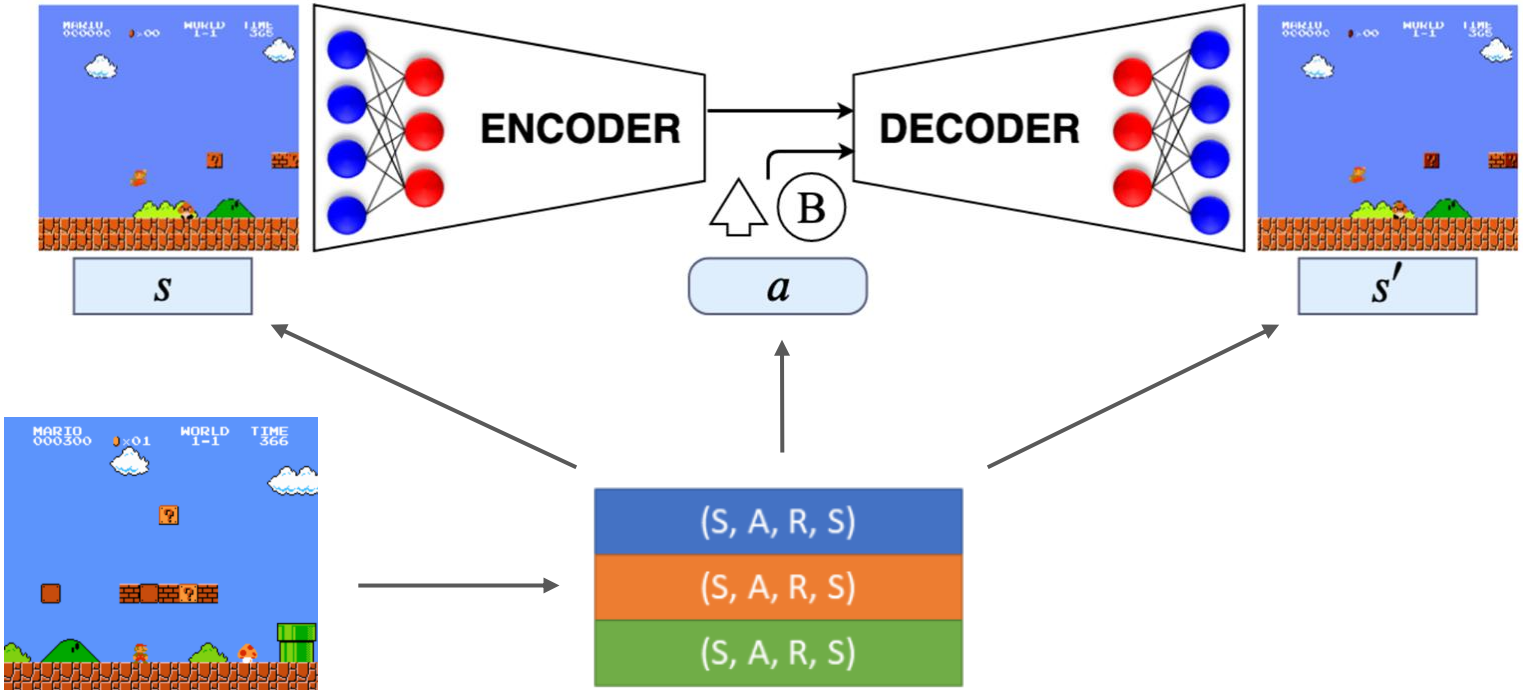

Окружение

Буфер памяти

Какие минусы у данного подхода?

Накопление ошибок при декодировании

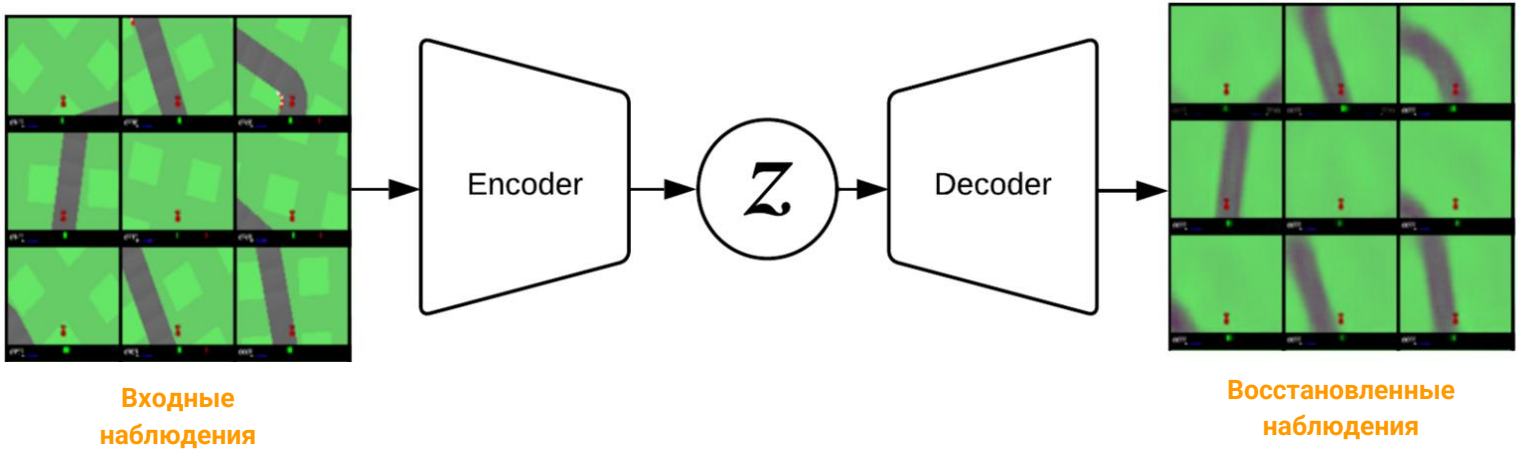

PlaNet

Модель латентной динамики среды

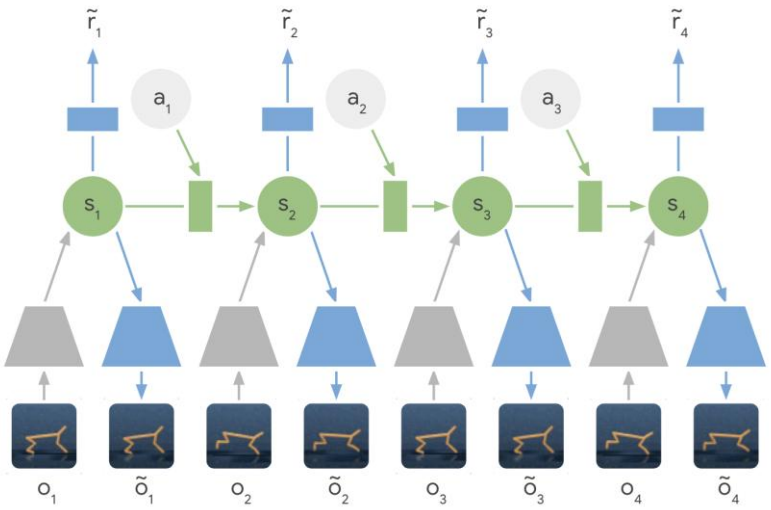

Планирование с помощью модели

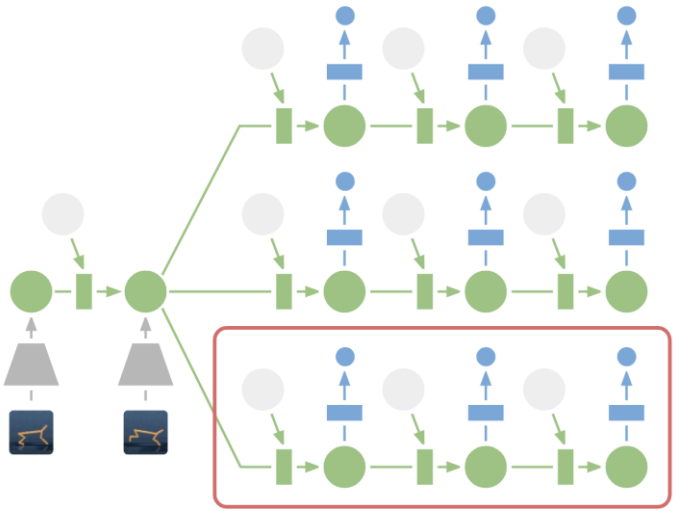

- наблюдение
- энкодер
- декодер
- латентное состояние
- выбранное действие
- награда
- модель, прогнозирующая следующее латентное состояние
- модель, прогнозирующая награду

Dreamer

1. Построение модели мира

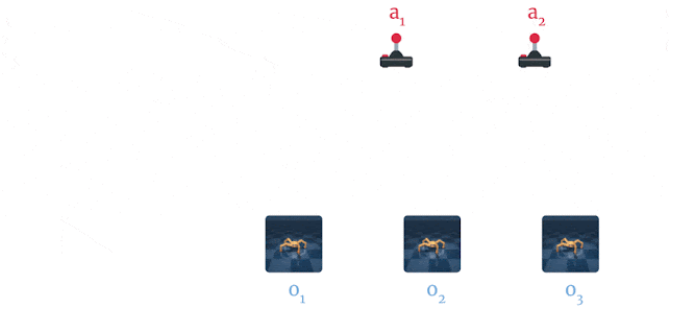

2. Обучение на воображаемых траекториях

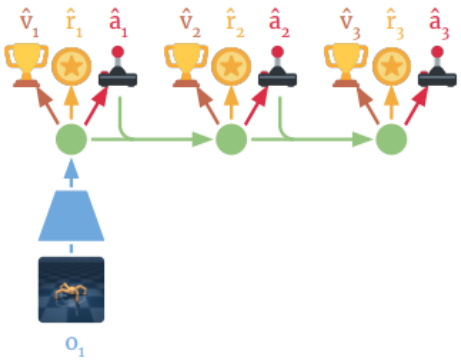

3. Применение изученного поведения

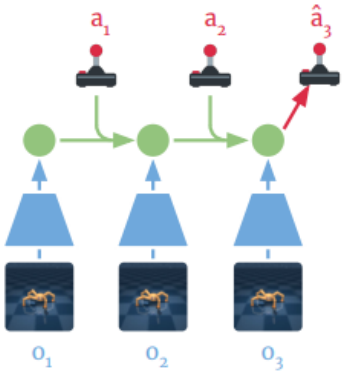

Практика

Домашнее задание (обязательное!)

1. Разобраться с кодом из практической части занятия, повторить эксперименты со своего аккаунта Google Colab
2. Реализовать класс, моделирующий стохастическую среду Frozen Lake 8x8
3. Обучить агента Dyna-Q, использующего стохастическую модель среды и сравнить с простым Q-агентом

Сроки выполнения: **до конца курса**

Рефлексия

Ключевые тезисы

Подведем итоги

1. Модель окружения представляет собой функции переходов и вознаграждения
2. Модель можно описать, выучить или иметь её симулятор
3. С помощью модели среды агенты могут, запускать симуляции развития событий и следовать наилучшему сценарию, а также генерировать дополнительный опыт из своего “воображения” для обучения
4. На текущий момент model-free методы, нацеленные на решение конкретной задач, чаще всего будут превосходить model-based решения, но эти решения не масштабируемы
5. Одна из основных проблем данного направления и направления RL в целом - потребность в симуляционных средах, которые адекватно отображают реальный мир и в которых можно ставить разнообразные задачи
6. Направление model-based обладает наиболее перспективных подходами, благодаря которым мы возможно создадим продвинутый ИИ, способный к построение внутренних моделей окружающего мира и эффективному планированию на основе этих моделей

Список материалов для изучения

1. Статья: Model-based Reinforcement Learning: A Survey
2. Статья: World models
3. Статья: Curiosity-Driven Learning Through Next State Prediction
4. Статья: Random Network Distillation: A New Take on Curiosity-Driven Learning

Следующий вебинар

10 декабря 2025

Model-based RL (Часть 2)

- Ссылка на вебинар будет в ЛК за 15 минут
- Материалы к занятию в ЛК — можно изучать
- Обязательный материал обозначен красной лентой

Вопросы?

Ставим “+”,
если вопросы есть

Ставим “–”,
если вопросов нет

Заполните, пожалуйста,
опрос о занятии
по ссылке в чате

Спасибо за внимание!