Reinforcement Learning

Обучение с использованием модели среды (продолжение)

otus.ru

REC **Проверить, идет ли запись**

Меня хорошо видно && слышно?

Ставим “+”, если все хорошо
“-”, если есть проблемы

Тема вебинара

Reinforcement Learning

Обучение с использованием модели среды

Андрей Канашов

Team Lead Data Scientist в ПИК

- Ценообразование и тарификация
- Рекомендательные системы
- Прогнозирование ключевых метрик
- Анализ клиентского поведения

Правила вебинара

Активно
участвуем

Off-topic обсуждаем
в учебной группе TG

Задаем вопрос
в чат или голосом

Вопросы вижу в чате,
могу ответить не сразу

Условные обозначения

Индивидуально

Время, необходимое
на активность

Пишем в чат

Говорим голосом

Документ

Ответьте себе или
задайте вопрос

Маршрут вебинара

- Продолжаем обсуждать Model-based подход
- Краткая история AlphaGo
- Monte Carlo Tree Search в алгоритмах AlphaGo
- Улучшение подхода с MCTS
- Практика
- Рефлексия

Цели вебинара

К концу занятия вы узнаете

1. Как можно улучшить планирование в воображении
2. Принцип работа алгоритма Monte Carlo Tree Search
3. Историю развития алгоритмов на базе MCTS на примере AlphaGo
4. Как реализовать алгоритм MCTS

Model-based RL

Часть 2

В предыдущих сериях …

Планирование в RL

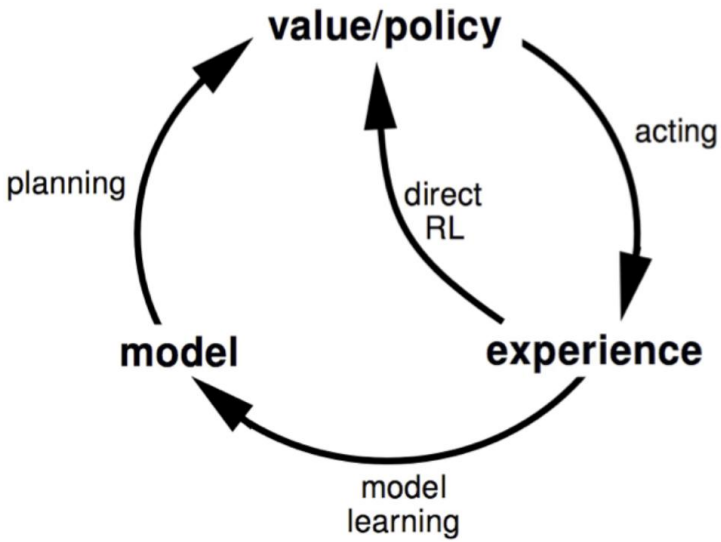

Выбор действия с помощью модели

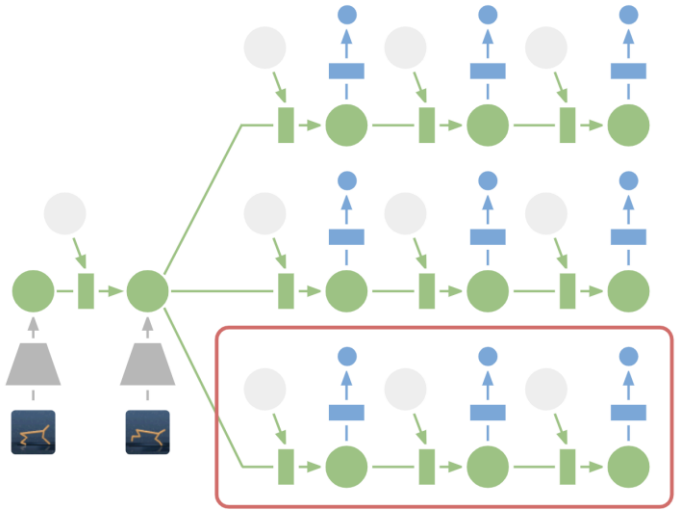

Как можно исследовать пространство действий более структурировано?

Игры

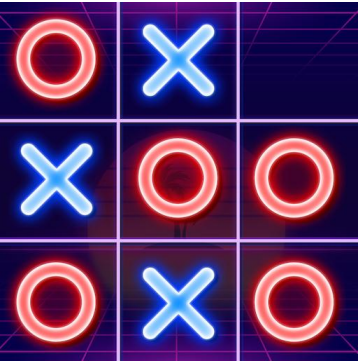

Дерево состояний

Допустимых комбинаций

255 168

Сколько всего может быть состояний в этой игре?

Число состояний

Шашки

10^20

Шахматы

10^50

Го

10^170

Атомы во вселенной

10^80

Число состояний

- Невозможно проанализировать все позиции, доступные в каждом состоянии.
- Нужен алгоритм, который дает приближенную оценку позицию.

Monte Carlo Tree Search

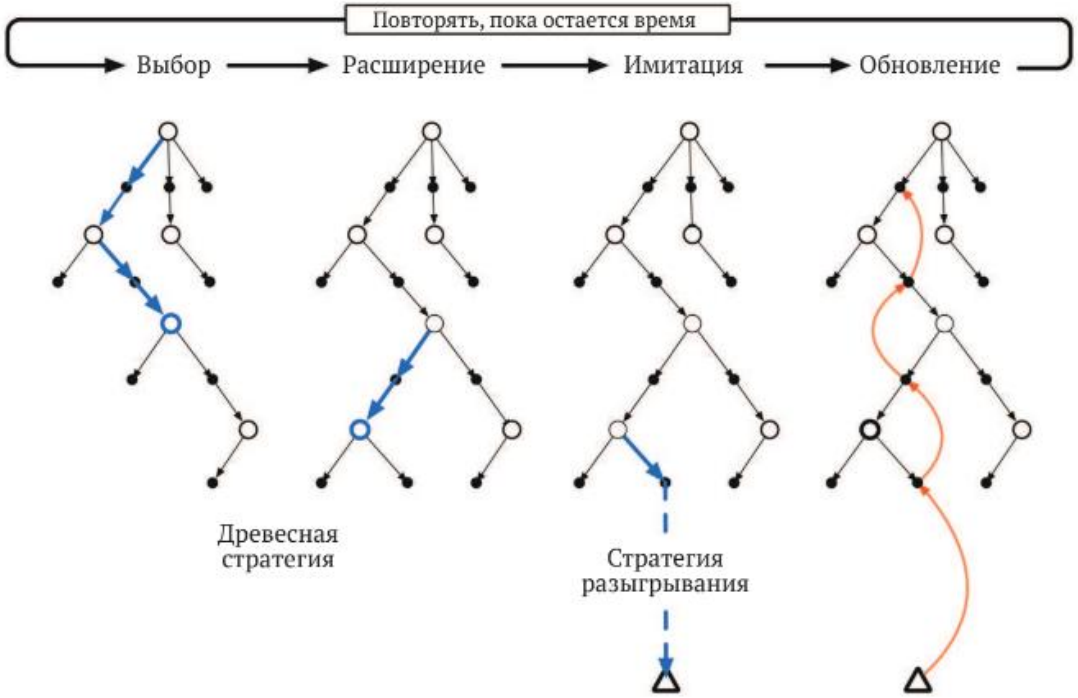

- **Выбор** - проход по дереву через узлы с наибольшим значением выбранного критерия
- **Расширение** - создание для конечного узла дочерних нод по количеству доступных действий
- **Имитация** - выбор одного из созданных узлов и разыгрывание партии до её завершения
- **Обновление** - корректировка параметров во всех пройденных узлах, исходя из полученного результата

Краткая история AlphaGo

Правила игры Го (вкратце)

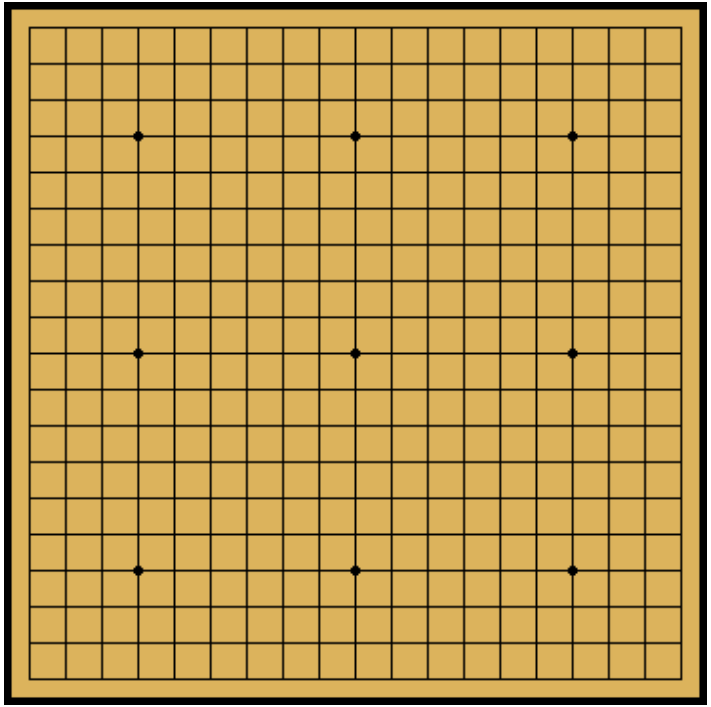

- Игра с полной информацией и нулевой суммой
- Игровое поле 19 x 19
- Два игрока по очереди выставляют камни своего цвета
- Игрок забирает себе камни противника, которые смог окружить своими камнями
- Побеждает тот, кто займёт больше территории + захваченные камни

Сравнение Шахмат и Го

ШАХМАТЫ

- 6 типов фигур (считая слонов за 1 тип)
- Поле 8x8
- 20 возможных первых ходов
- Задача – побить короля без возможности того избежать атаки
- Возможна ничья
- Количество игр $35^{80} \sim 10^{123}$
- Гроссмейстерский уровень игры заключается в знании дебютов, которые много раз сыграны и опробованы, изучении игр соперника. По сути, единственное поле для «творчества» – миттельшпиль (и то не всегда). Существуют качественные оценки силы позиции и каждой фигуры; стратегии игры, которые значимо улучшают качество игры

ГО

- 1 тип фигур
- Поле 19x19
- 361 возможный первый ход
- Задача – захватить больше территории
- Нет ничьих
- Количество игр $250^{150} \sim 10^{360}$
- Гроссмейстеры даже высокого дана часто объясняют свои ходы «интуицией» выработонной годами игры в го; несмотря на наличие некоторых рекомендаций, они в большей части полезны для начинающих игроков и игроков первых данов.

Почему Го это сложно?

- Начало партии с произвольной позиции
- Большая ширина дерева возможных ходов (~35 в шахматах против ~250 в Го)
- Достаточно длинные партии (~40 ходов в шахматах и ~200 в Го)
- Сложность оценки позиции и формализации логики игроков
- Постоянная оценка ситуации, как на тактическом, так и на стратегическом уровнях

Победное шествие алгоритмов AlphaGo

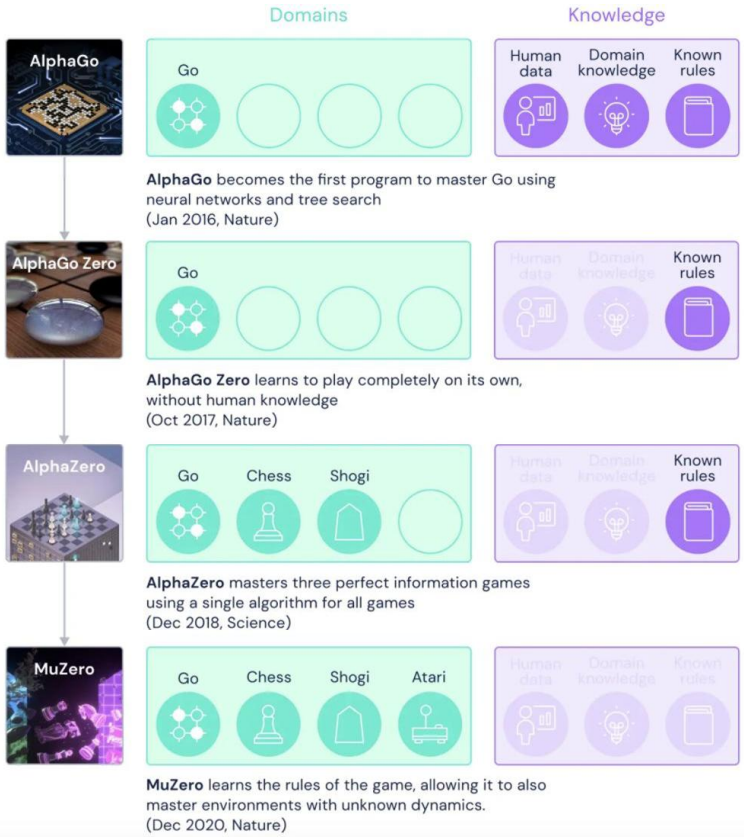

Google DeepMind

Победное шествие алгоритмов AlphaGo

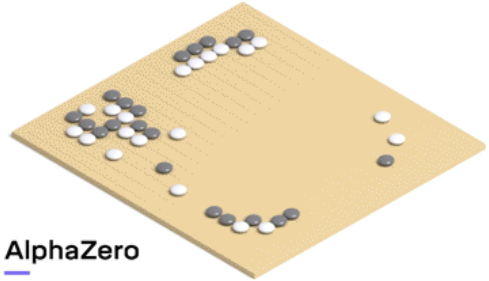

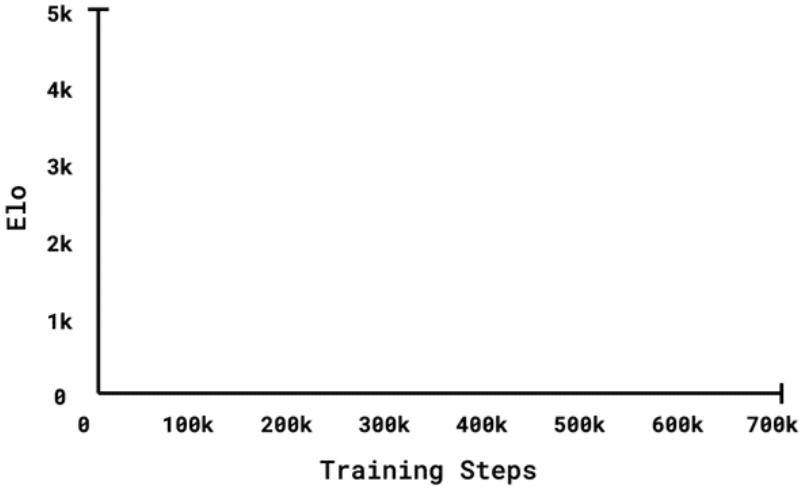

Monte Carlo Tree Search в алгоритмах AlphaGo

Применение MCTS в AlphaGo Zero

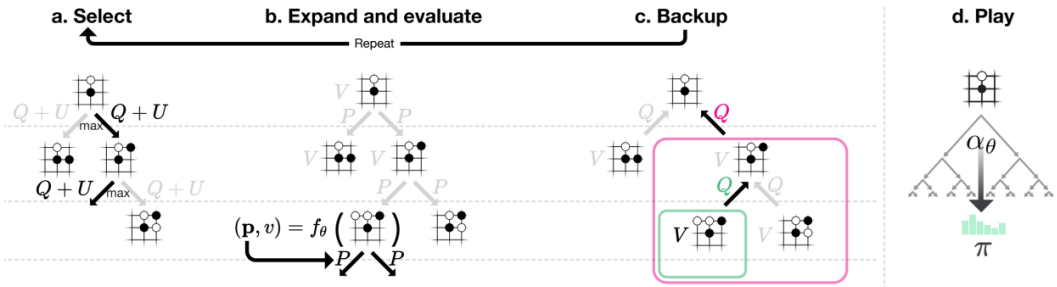

V - оценка выигрышности позиции

P - вероятность хода в позиции

} Прогнозирует сеть

N - количество посещения позиции во время “раздумий” перед ходом

Q - оценка выигрышности хода
Q = sum(дочерние V) / N

U - добавка для доп. исследования
U = P / (1 + N)

} Рассчитываем во время раскрытия дерева

1. Корневым узлом является текущая (реальная) позиция на доске.
2. (a) Спускаемся по дереву, выбирая ходы с наибольшей суммой Q и U.
3. (b) Когда доходим до “пустого” ребра, создаём новую ноду и запускаем для неё сеть, определяя её V и вероятности P для ходов из этой ноды (позиции).
4. (b) Создаём новые рёбра и записываем туда P, N = 0, Q = 0.
5. (c) Поднимаемся к корню по пройденным нодам и рёбрам и корректируем N и Q.
6. Выполняем 1600 раз шаги 2 - 5.
7. (d) Выбираем доступный ход из корневого узла у которого больше N.

Обучение MCTS в AlphaGo Zero

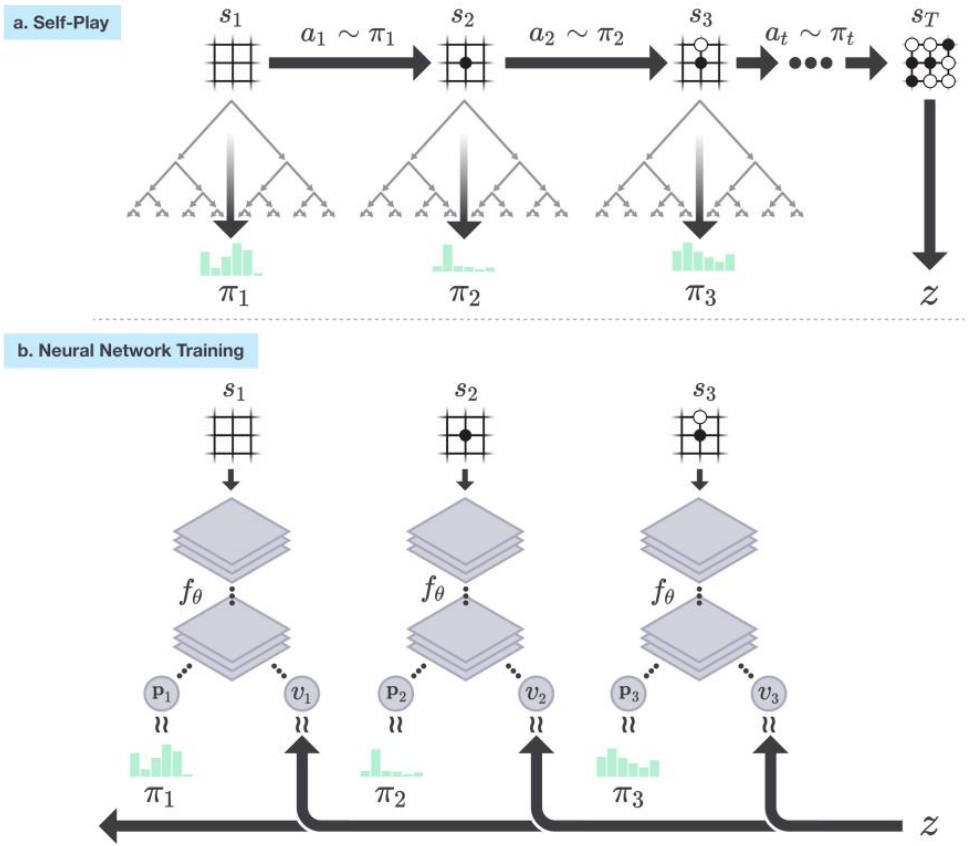

1. Взять текущую версию сети и сыграть 25K игр с самой собой, собирая:
   - S - позиция на доске
   - P(A) - скорректированные вероятности ходов после MCTS
   - Z - результат игры
2. Поместить 25K игр в буфер объёмом 500K игр.
3. Выбрать из буфера 1K батчей, размером 2048, где каждый элемент - (S, P(A), Z) и провести цикл обучения.
4. Сравнить новую версию сети с текущей и выбрать лучшую на основе 400 игр (требуется 55% побед).
5. Продолжать пока не достигнете желаемого результата.

AlphaGo Zero: Функция ошибки

$$l = \underbrace{(z - v)^2}_{} - \underbrace{\boldsymbol{\pi}^{\mathrm{T}} \log \boldsymbol{p}}_{} + \underbrace{c\|\theta\|^2}_{}$$

Z (с каким результатом закончилась партия) не должно отличаться от V (какой исход предсказала сеть)

Приближение вероятностей, полученных из MCTS

Регуляризатор

AlphaGo Zero: Архитектура сети

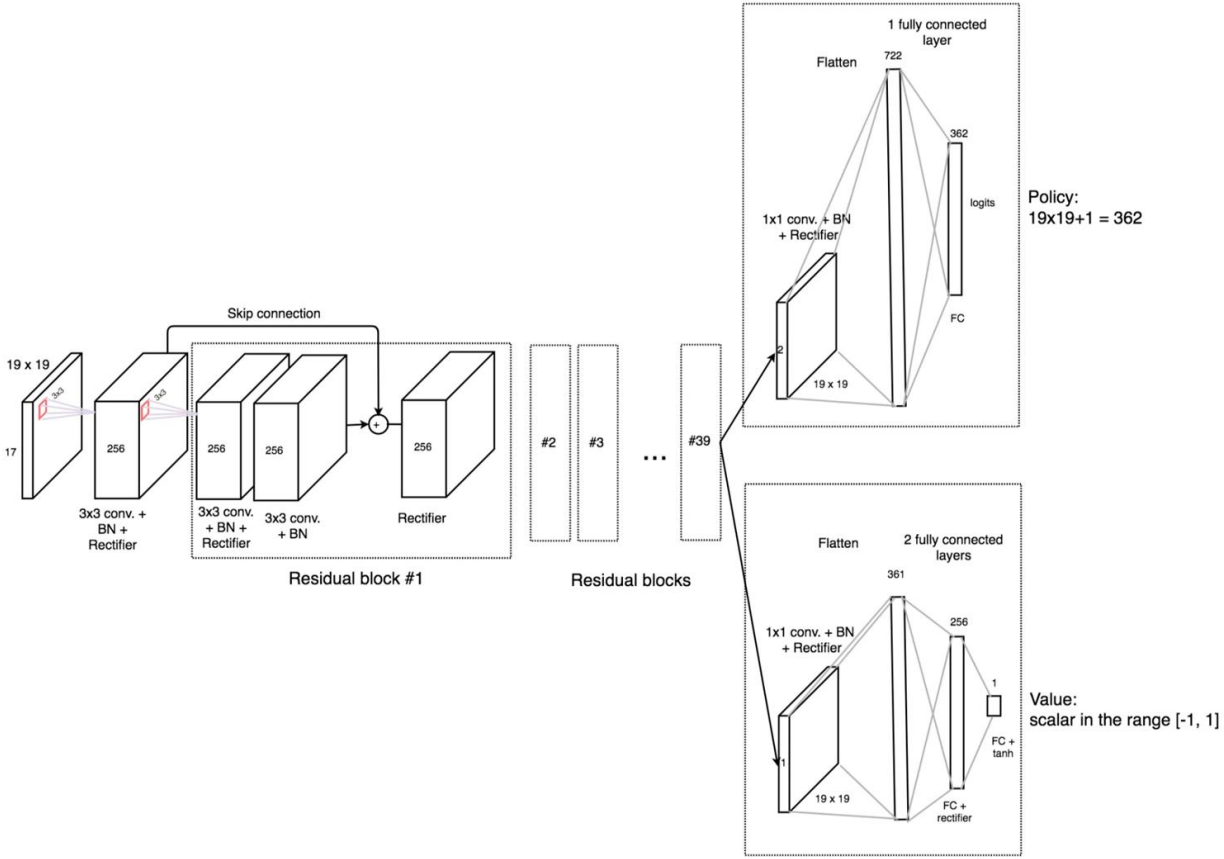

AlphaGo Zero: Пространство признаков

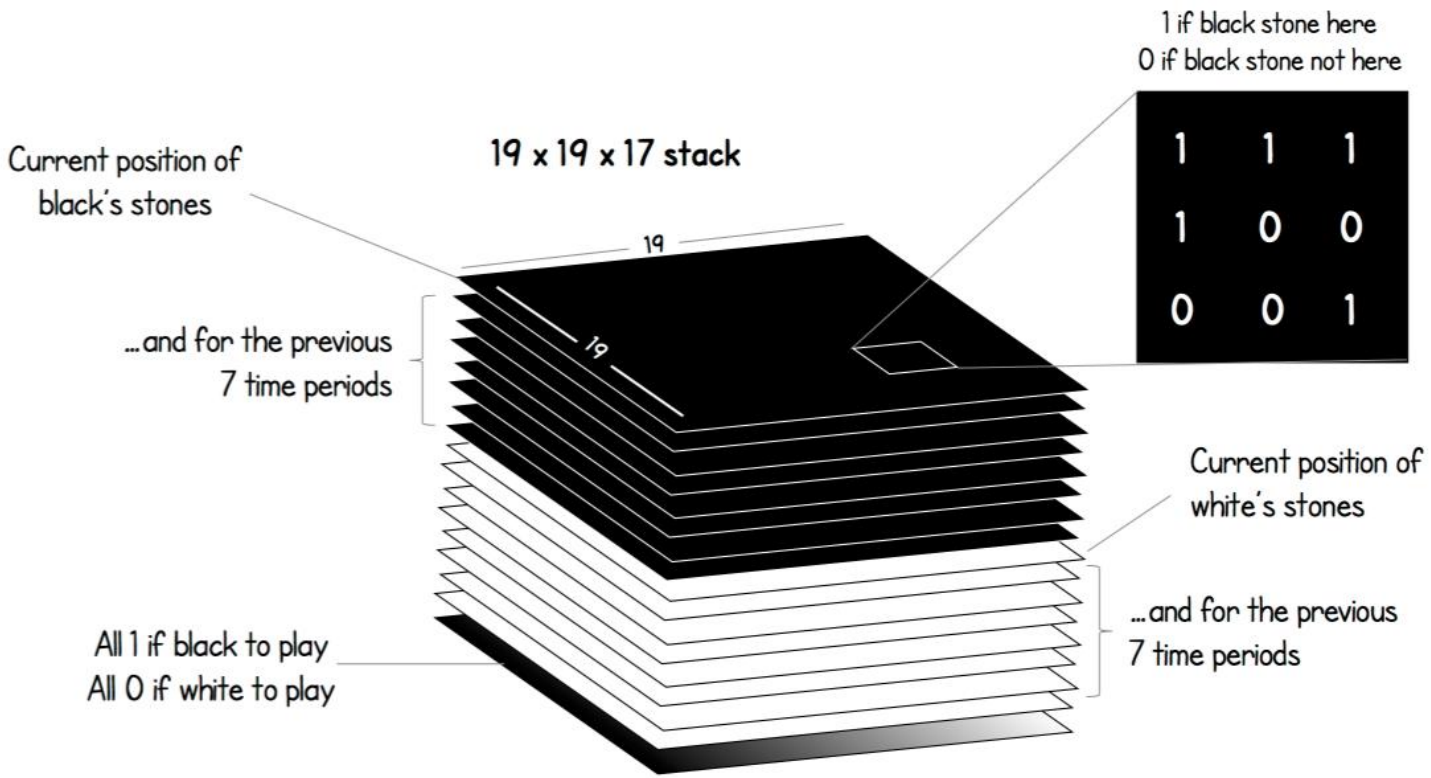

Для чего передавать информацию
о предыдущих шагах?

Что можно изменить для переноса алгоритма AlphaGo Zero на другие среды?

Дистилляция MCTS и моделирование симулятора

Моделирование симулятора

AlphaZero has 1 network

		from		to
prediction	f:	s	→	p, v

MuZero has 3 networks

		from		to
prediction	f:	s	→	p, v
dynamics	g:	s, a	→	r, s
representation	h:	o	→	s

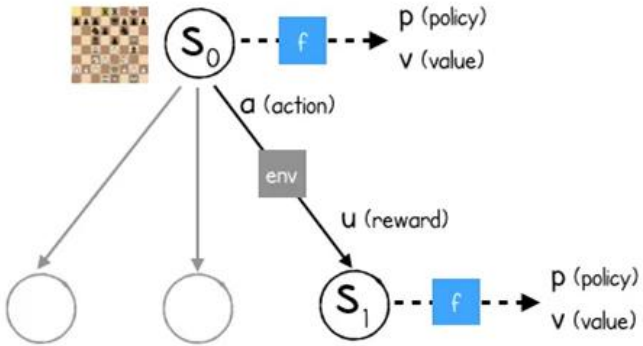

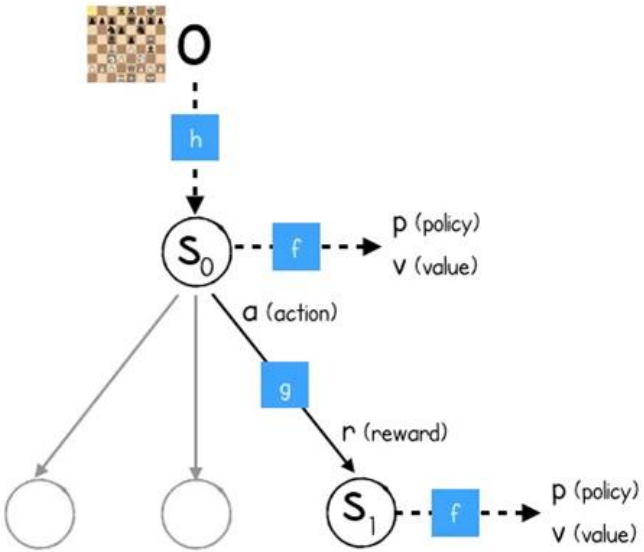

Результаты MuZero

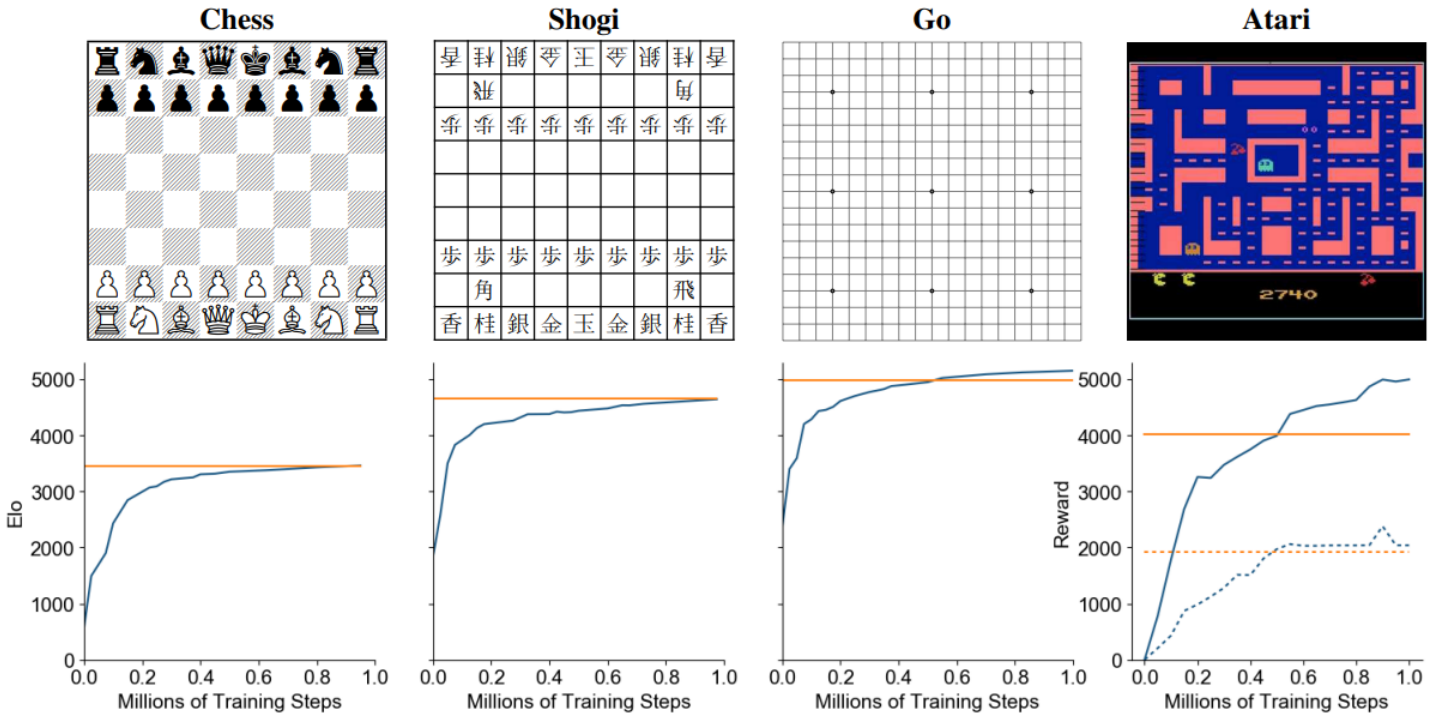

против AlphaZero

против людей и R2D2

синий – MuZero
оранжевый - AlphaZero

OTUS | ОНЛАЙН ОБРАЗОВАНИЕ

Практика

Домашнее задание (опциональное)

1. Разобраться с кодом из практической части занятия
2. Попробовать алгоритм MCTS в другой среде на ваш выбор

Сроки выполнения: **до конца курса**

Рефлексия

Ключевые тезисы

Подведем итоги

1. Для выполнения более структурированного выбора действий при планировании, хорошим вариантом будет поиск по дереву, например, с помощью алгоритма MCTS
2. Использование RL в MCTS для предсказания ценности состояния и вероятности действий позволяет существенно сузить в ширину и уменьшить в глубину дерево поиска
3. Построение модели симулятора среды позволяет обобщать решение на базе MCTS на произвольные дискретные среды

Следующий вебинар

15 декабря 2025

Иерархическое обучение с подкреплением

- Ссылка на вебинар будет в ЛК за 15 минут
- Материалы к занятию в ЛК — можно изучать
- Обязательный материал обозначен красной лентой

Вопросы?

Ставим “+”,
если вопросы есть

Ставим “–”,
если вопросов нет

Заполните, пожалуйста,
опрос о занятии
по ссылке в чате

Спасибо за внимание!